TECNOLÓGICO NACIONAL DE MÉXICO

Departamento de Sistemas y Computación

Ingeniería en Sistemas Computacionales

REPORTE TÉCNICO

Inferencia Estadística y Toma de Decisiones en Ingeniería

Latencia HTTP: Monolito vs. Microservicios

Asignatura	Fundamentos de Ciencia de Datos
Actividad	Actividad Integradora — Unidad 2
Caso de estudio	Caso A: Arquitectura de Software (Monolito vs. Microservicios)
Equipo / integrantes	- Moreno Rogel Erick - 22090700 - Avilez Delgado Ismael - 22090589 - Bautista Díaz Martín Antonio - 22090601
Repositorio GitHub	https://github.com/izzzma0205/fdc-u2-caso-a
Fecha de entrega	16/Octubre/2026

Resumen

Se evaluó si la arquitectura de microservicios incrementa la latencia de respuesta HTTP respecto a un monolito, empleando 500 observaciones sintéticas (250 por grupo; 483 tras eliminar atípicos con el criterio 1.5×IQR). La latencia media fue de 123.20 ms en el monolito y 124.61 ms en microservicios. El intervalo de confianza del 95 % para la diferencia de medias (Micro − Mono) fue (-6.80, 9.63) ms, el cual contiene al cero. La prueba t unilateral ($t = 0.338$; $p = 0.368$) no rechaza H_0 con $\alpha = 0.05$: no hay evidencia estadística de que microservicios incremente la latencia. Se advierte que la potencia de la prueba es limitada para efectos pequeños, por lo que se recomienda ampliar la muestra antes de comprometer SLAs estrictos.

1. Objetivo

Aplicar técnicas de estadística descriptiva, simulación del Teorema Central del Límite, estimación por intervalos de confianza y pruebas de hipótesis paramétricas para sustentar una decisión técnica formal sobre la arquitectura de un sistema de software, utilizando Python (numpy, pandas, matplotlib, seaborn, scipy).

2. Caso de estudio y datos

Problema: determinar si la sobrecarga de red en microservicios incrementa la latencia respecto a un monolito.

- **Variable cuantitativa (Y):** latencia de respuesta HTTP en milisegundos (ms).
- **Variable cualitativa (X):** tipo de arquitectura (Monolito vs. Microservicios).

Obtención del dataset. No se dispuso de un conjunto de datos público con mediciones pareadas de la misma aplicación en ambas arquitecturas, por lo que se utilizó generación sintética justificada (semilla 42, n = 250 por grupo). Se empleó la distribución Gamma, adecuada para tiempos de respuesta por ser positiva y asimétrica a la derecha, más un desplazamiento fijo que representa el costo base de procesamiento y red: Monolito ~ Gamma(2.5, 35) + 40 y Microservicios ~ Gamma(2.2, 40) + 45. Los archivos se almacenan en data/ (dataset_caso_a.csv y dataset_caso_a_limpio.csv).

3. Resultados

3.1 Bloque 1 — Estadística descriptiva y limpieza

El conjunto no presentó valores ausentes y los tipos de datos fueron los esperados (latencia numérica continua y grupo categórico). Se aplicó el criterio 1.5×IQR por grupo (Tabla 1): se removieron 10 atípicos en Monolito y 7 en Microservicios, todos en la cola superior, quedando 240 y 243 observaciones (N = 483 ≥ 400).

Grupo	n antes	Límite inferior	Límite superior	Outliers	n después
Monolito	250	-5.79	250.65	10	240
Microservicios	250	-12.36	260.49	7	243

Tabla 1. Detección de valores atípicos (1.5×IQR) por grupo.

Estadístico	Monolito	Microservicios
n	240	243
Media (ms)	123.20	124.61
Mediana (ms)	117.01	113.97
Desv. estándar s (ms)	43.53	48.20
Varianza s² (ms²)	1,894.79	2,323.63
Asimetría	0.616	0.770
Curtosis (exceso)	-0.159	-0.094

Tabla 2. Estadísticos descriptivos por grupo (datos depurados).

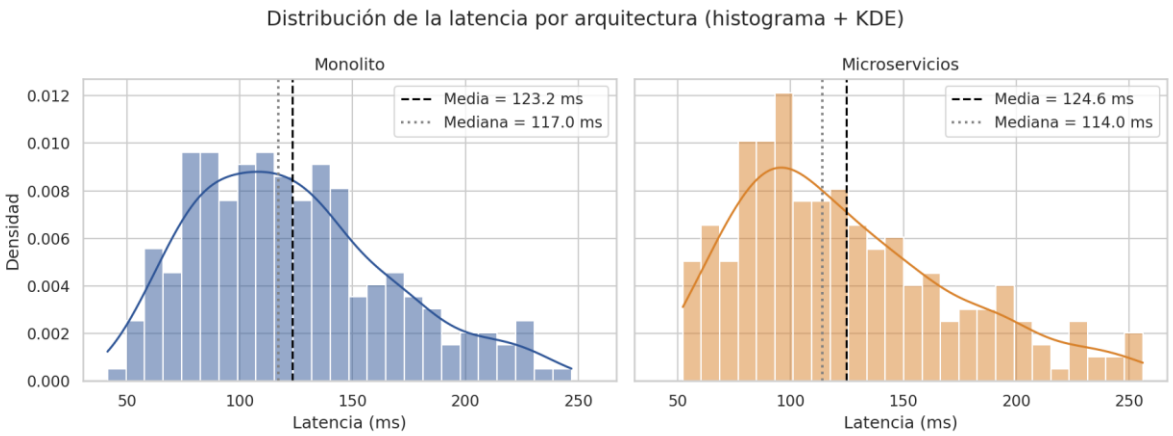


Figura 1. Histogramas con curva KDE por arquitectura.

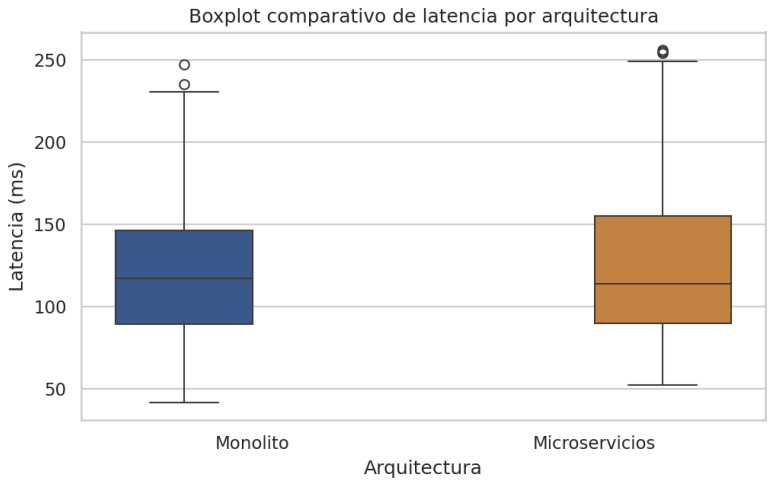


Figura 2. Diagramas de caja comparativos.

Ambas distribuciones tienen asimetría positiva (0.62 y 0.77): la media supera a la mediana porque una cola de respuestas lentas arrastra el promedio hacia la derecha. La curtosis en exceso es ligeramente negativa en ambos grupos, es decir, colas similares a las de una normal tras la depuración. Microservicios presenta mayor dispersión (s = 48.20 ms frente a 43.53 ms). Las distribuciones se traslapan casi por completo y sus medias son muy cercanas.

3.2 Bloque 2 — Distribuciones de muestreo y Teorema Central del Límite

Con la muestra global (N = 483; media = 123.91 ms; s = 45.90 ms; asimetría = 0.71) se generaron K = 1,000 remuestras con reemplazo para n ∈ {5, 15, 30, 60}. La Tabla 3 compara el error estándar empírico con el teórico $\sigma_{\bar{x}} = s/\sqrt{n}$ y la Figura 3 muestra las distribuciones de las medias muestrales.

n	Media de medias	SE empírico	SE teórico (s/√n)	Dif. relativa	Asimetría	Shapiro p
5	123.83	20.45	20.53	-0.35 %	0.287	< 0.0001
15	123.65	11.50	11.85	-3.00 %	0.216	0.0115
30	123.65	8.51	8.38	1.61 %	0.088	0.0293
60	123.75	6.05	5.93	2.19 %	0.207	0.0141

Tabla 3. Error estándar empírico vs. teórico y forma de la distribución de las medias.

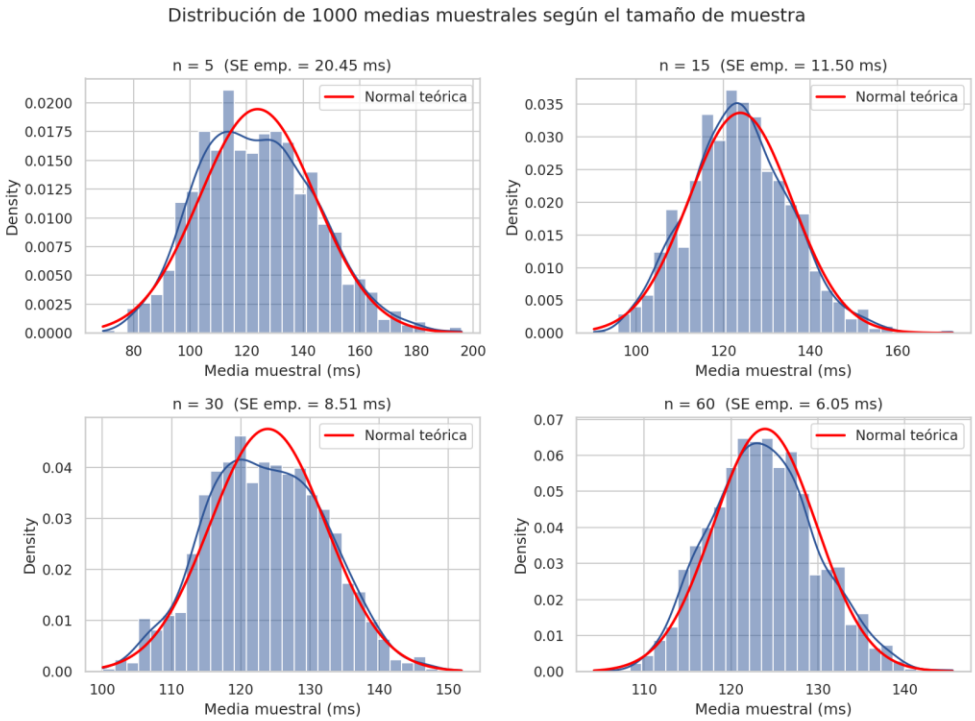


Figura 3. Distribución de 1,000 medias muestrales por tamaño de muestra, con la normal teórica (línea roja).

El error estándar empírico coincide con el teórico con diferencias relativas entre −3.0 % y +2.2 %, atribuibles al ruido de simulación, y disminuye con la regla de la raíz cuadrada (≈ 20.5 ms con n = 5 hasta ≈ 6.1 ms con n = 60). Aunque la población es asimétrica, la asimetría de las medias se reduce (la teoría predice $\gamma/\sqrt{n}$ ≈ 0.32, 0.18, 0.13 y 0.09), y los histogramas se ajustan a la curva normal. La prueba de Shapiro-Wilk aún detecta desviaciones menores respecto a la normalidad exacta ($p < 0.05$), pero con 1,000 medias es muy sensible; la asimetría residual es leve. Se concluye que se cumple el Teorema Central del Límite y que, desde n ≈ 30, la aproximación normal es adecuada para inferencia.

3.3 Bloque 3 — Estimación por intervalos de confianza

IC para la media poblacional (μ). Se utiliza la distribución t-Student con n − 1 grados de libertad porque la desviación estándar poblacional σ es desconocida y se estima con s; el TCL justifica la normalidad aproximada de la media muestral pese a la asimetría de la población. Con N = 483 los cuantiles t y Z son prácticamente idénticos (Tabla 4).

Confianza	t crít.	IC con t (inf, sup)	Amplitud	z crít.	IC con Z (inf, sup)
90%	1.648	(120.47, 127.35)	6.88	1.645	(120.48, 127.35)
95%	1.965	(119.81, 128.02)	8.21	1.960	(119.82, 128.00)
99%	2.586	(118.51, 129.31)	10.80	2.576	(118.53, 129.29)

Tabla 4. Intervalos de confianza para la media poblacional general (ms).

Con 95 % de confianza, la latencia media global se encuentra entre 119.81 y 128.02 ms. Al aumentar la confianza el intervalo se ensancha: se gana certeza a costa de precisión.

IC para la diferencia de medias ($\mu_1 - \mu_2$). Se define μ_1 = Microservicios y μ_2 = Monolito. La prueba de Levene (W = 1.842; p = 0.175 > 0.05) no rechaza la homogeneidad de varianzas, por lo que se usa el intervalo con varianza combinada (gl = 481). La diferencia observada es 1.41 ms con error estándar de 4.18 ms, y el IC al 95 % es (-6.80, 9.63) ms. La corrección de Welch produce un resultado prácticamente idéntico (-6.80, 9.62), por lo que la conclusión no depende del método.

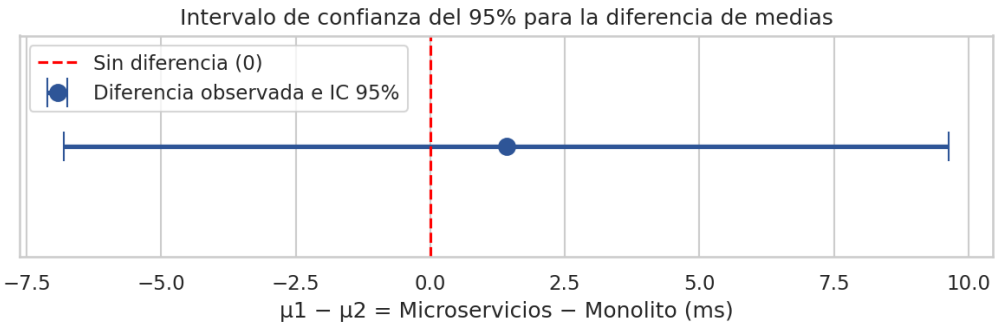


Figura 4. Intervalo de confianza del 95 % para $\mu_1 - \mu_2$.

¿0 ∈ IC? Sí. El cero pertenece al intervalo, por lo que los datos son compatibles con la ausencia de diferencia entre arquitecturas: no puede afirmarse con 95 % de confianza que una sea más lenta que la otra. En términos prácticos, la diferencia real podría ir desde una ventaja de ≈ 6.8 ms para microservicios hasta una penalización de ≈ 9.6 ms. Si el SLA tolera un incremento de ~10 ms, incluso el peor escenario plausible queda dentro de lo aceptable.

3.4 Bloque 4 — Teoría de decisión (prueba de hipótesis)

Hipótesis. Como la pregunta de ingeniería es si microservicios incrementa la latencia, la prueba es unilateral derecha:

- **H_0:** μ_micro ≤ μ_mono — la arquitectura de microservicios no incrementa la latencia media respecto al monolito.
- **H_1:** μ_micro > μ_mono — la arquitectura de microservicios sí incrementa la latencia media (existe sobrecarga de red significativa).

Matriz de decisión y costos de error.

Decisión	H_0 verdadera (microservicios NO es más lenta)	H_0 falsa (microservicios SÍ es más lenta)
No rechazar H_0	Decisión correcta: se mantiene la migración planeada.	ERROR TIPO II (β): no se detecta una degradación real de latencia.
Rechazar H_0	ERROR TIPO I (α): se concluye que microservicios es más lento cuando no lo es.	Decisión correcta: se detecta la sobrecarga y se actúa a tiempo.

Tabla 5. Matriz de decisión.

Error	Costo operativo / técnico
Tipo I (α = 0.05)	Falsa alarma: se frena, rediseña o revierte una arquitectura que en realidad no degrada el servicio; horas de ingeniería desperdiciadas, retraso del roadmap y descarte de beneficios reales de escalabilidad y despliegue independiente.
Tipo II (β)	Detección fallida: se despliega o mantiene una arquitectura con mayor latencia; riesgo de incumplir SLAs, peor experiencia de usuario, mayor consumo de infraestructura y rediseño tardío y más caro en producción.

Tabla 6. Costo operativo o técnico de los errores Tipo I y Tipo II.

Prueba paramétrica. Se fijó α = 0.05 y se ejecutó scipy.stats.ttest_ind con varianzas iguales (consistente con Levene) y alternativa unilateral derecha.

Concepto	Resultado
Nivel de significancia (α)	0.05
Prueba	t de Student para dos muestras independientes, cola derecha (varianzas iguales)
Estadístico t (gl)	0.3384 (gl = 481)
Valor crítico t(0.95)	1.6480
p-value unilateral	0.3676
p-value bilateral (referencia)	0.7352
d de Cohen	0.031
Veredicto	NO RECHAZAR H_0

Tabla 7. Resultados de la prueba de hipótesis.

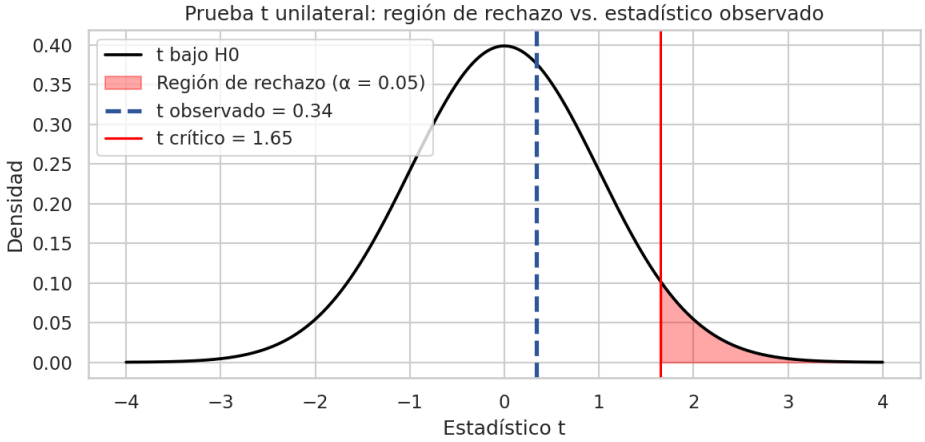


Figura 5. Región de rechazo y estadístico t observado.

Veredicto: NO RECHAZAR H_0. El estadístico t = 0.338 es menor que el valor crítico 1.648, y el p-value (0.368) es mayor que α = 0.05. No existe evidencia estadística suficiente de que microservicios incremente la latencia media respecto al monolito, resultado coherente con el IC del Bloque 3.

Tamaño del efecto y riesgo de Error Tipo II. El d de Cohen es 0.03 (efecto despreciable). No rechazar H_0 no demuestra la ausencia de diferencia: con ≈ 240 observaciones por grupo la

prueba tiene una potencia de 0.77 para detectar un incremento de 10 ms (β ≈ 0.23), pero solo de 0.37 para un incremento de 5.5 ms. Como los datos son sintéticos se conocen las medias teóricas del generador (127.5 ms y 133.0 ms): existe una diferencia real de 5.5 ms que la muestra no logró detectar, lo cual ilustra un Error Tipo II causado por la baja potencia ante efectos pequeños y la alta variabilidad (s ≈ 46 ms). Detectar 5.5 ms con 80 % de potencia requeriría ≈ 864 observaciones por grupo.

4. Conclusiones y recomendación técnica

- Ambas arquitecturas presentan distribuciones de latencia asimétricas a la derecha y muy similares (medias 123.2 y 124.6 ms).
- La simulación confirmó el Teorema Central del Límite y la fórmula σ_x̄ = s/√n, justificando el uso de inferencia basada en la distribución t.
- El IC al 95 % para $\mu_1 - \mu_2$ es (-6.80, 9.63) ms y contiene al cero; la prueba t unilateral (p = 0.368) no rechaza H_0 con α = 0.05.
- La prueba tiene potencia limitada para efectos pequeños (≈ 5 ms); la ausencia de significancia no equivale a ausencia de efecto.

Recomendación de ingeniería:

1. Con los datos disponibles, la migración a microservicios no muestra una penalización significativa de latencia; el costo adicional de red, si existe, es como máximo de ≈ 10 ms (extremo superior del IC), por lo que no es por sí solo una razón técnica para descartar la arquitectura.
2. Antes de comprometer SLAs con márgenes menores a 10 ms, ampliar la muestra con pruebas de carga reales (Locust o Apache Bench) hasta ≈ 900 mediciones por grupo y comparar también percentiles altos (p95/p99), dado que la distribución tiene cola derecha.
3. Mitigar de forma proactiva la sobrecarga de red típica de microservicios (comunicación gRPC, caché en el gateway, agrupación de llamadas entre servicios) y mantener monitoreo continuo de latencia.